

MedR-Bench 评估报告：Gemini-2.0-FT Oracle 诊断 (957 例)

评估对象：HuggingFace 论文推理 `oracle_diagnosis.json` 中的 `gemini2-ft`
Judge 模型：本地 Qwen2.5-7B-Instruct (`judge_server_transformers.py`, 无 Bing 网页搜索)
Ground Truth：`data/MedRBench/diagnosis_957_cases_with_rare_disease_491.json`
生成日期：2026-05-28

目录

- 1. 结果文件位置
- 2. 运行完整性检查
- 3. 与论文数据对比
- 4. 核心结论
- 5. 典型案例
- 6. Accuracy 定义
- 7. Efficiency / Factuality / Completeness 指标定义
- 8. Completeness 差距深度分析
- 9. 代码与评估入口
- 10. 答案诱导偏差研究方向
- 11. 后续可探索方向
- 12. 建议使用方式
- 13. 汇总表

1. 结果文件位置

任务	目录
诊断准确率 (Accuracy)	<code>src/Evaluation/acc_results_qwen_judge_paper_957/gemini2-ft/</code>
推理质量 (Efficiency / Factuality / Completeness)	<code>src/Evaluation/reasoning_results_qwen_judge_paper_957/gemini2-ft/</code>

每个病例一个 JSON 文件，命名格式：`PMCxxxxx.json`。

单条 JSON 关键字段

Accuracy 结果

字段	含义
<code>accuracy</code>	<code>true / false</code> , Judge 判断预测诊断是否与 GT 语义等价

Reasoning 结果

字段	代码名	论文名
----	-----	-----

字段	代码名	论文名
efficiency	efficiency	Efficiency（推理效率）
factuality	factuality	Factuality（真实性，代码拼写为 factuality）
recall	recall	Completeness（完整性）
reasoning_eval	—	逐步推理及每步 efficiency/factuality 评判
gt_reasoning_eval	—	GT 推理步骤及是否被模型覆盖（hit）

本地复算脚本：

```
python scripts/analyze_reasoning_paper_957.py
```

2. 运行完整性检查

检查项	结果
Reasoning 结果文件数	957 / 957
Accuracy 结果文件数	957 / 957
efficiency / factuality / recall 缺失	0
reasoning_eval 为空	0
推理步数为 0	0

结论：957 条评估完整，无缺文件、无缺失字段。

src/Evaluation/gemini2-ft_error.log 中仅有 4 行历史错误，来自早期 35 例 + 远程 GPT API（敏感词拦截），不是本次 957 全量 Qwen 评估产生。

步骤级统计

统计量	数值
每例平均推理步数	6.95（中位 7）
每例平均 GT 步骤数	7.11（中位 7，最大 17）
被判为 Reasoning 的步占比	93.6%
被判为 Citation	5.7%
被判为 Redundancy / Repetition	< 1%

164 例 completeness = 0%：不是未评完，而是 Judge 对全部 GT 步骤均判 hit: false（见第 5 节案例说明）。

3. 与论文数据对比

论文来源：[Nature Communications — MedR-Bench](#)

对照表：Extended Table 3（Oracle Accuracy）、Extended Table 4（Oracle Reasoning, all diseases）

论文设置：**GPT-4o 作 Reasoning Evaluator**；Factuality 评估[含网页搜索](#)；Accuracy 使用 Prompt 19（语义等价，非字符串 exact match）。

3.1 主表：957 全量 vs 论文

指标	论文 (Gemini-2.0-FT, Oracle)	本次 (Qwen-7B, 957)	差距
Accuracy	86.83%	81.09% (776/957)	-5.74 pp
Efficiency	95.89%	93.61%	-2.28 pp
Factuality	98.23%	98.15%	-0.08 pp
Completeness	83.28%	31.47%	-51.81 pp

3.2 491 罕见病子集（checked_rare_disease 非空）

指标	论文 (Table 5, rare)	本次 (491)
Efficiency	96.45%	94.38%
Factuality	98.39%	98.24%
Completeness	84.30%	31.92%

3.3 Completeness 分布（957 例）

区间	病例数	占比
0-50%	703	73.5%
50-70%	173	18.1%
70-90%	65	6.8%
90-100%	16	1.7%

3.4 35 例 test_cases 子集（交叉验证）

数据源	n	Efficiency	Factuality	Completeness
论文 (GPT-4o)	~35	~95.89%	~98.23%	~83.28%
本次 957 中的 35 例	35	92.90%	97.40%	34.50%
历史 35 例 Qwen	35	85.97%	90.12%	32.68%
历史 35 例 GPT	34	86.24%	90.69%	74.79%

4. 核心结论

4.1 数据与流程没有问题

- 推理文本与 `oracle_diagnosis.json` 中 `gemini2-ft` 一致（抽检 200 例，0 处不一致）。
- 957 条结果字段完整，聚合公式正确。
- Accuracy 81.09%** 已本地复算确认（776/957）。

4.2 与论文差距的原因

指标	是否与论文可比	主要原因
Accuracy	部分可比	Qwen-7B vs GPT-4o 语义等价判断更严（约 -5.7 pp）
Efficiency	高度可比	仅差 2.3 pp
Factuality	几乎一致	仅差 0.08 pp；无网页搜索影响很小
Completeness	不宜直接对比	Qwen-7B 在 hit-check 任务上系统性偏严（约 -52 pp）

4.3 Judge 差异是 Completeness 偏低的主因

同一套论文推理、同一评估代码，仅更换 Judge：

- Qwen-7B**（35 例或 957 例）：Completeness 稳定在 **~31–33%**
- GPT-4o**（35 例）：Completeness **~75%**，接近论文 **83%**

说明 Completeness 差距主要来自 **Judge 模型能力**，而非推理数据错误或评估 pipeline bug。

5. 典型案例

5.1 PMC11625232（同一病例，不同 Judge）

模型推理与 GT 均指向：眶蜂窝织炎 + 鼻窦炎 + 硬膜外 empyema。

Judge	GT 步骤数	Hit 数	Recall
Qwen-7B	9	5	55.6%
GPT-4o	8	8	100%

Qwen 将「epidural empyema」「排除 cavernous sinus thrombosis」等 GT 步骤判为未覆盖，而 GPT 判为已覆盖。

5.2 PMC11321471（Completeness = 0% 但诊断正确）

- 模型最终答案：`Gastrointestinal Stromal Tumor (GIST) of the mesentery`
- GT 诊断：`Gastrointestinal Stromal Tumor (GIST)`
- 模型 6 步推理逐步分析至 GIST，Efficiency/Factuality 均为 1.0
- 但 10 个 GT 步骤 **全部 hit: false → recall = 0%**

说明：Completeness 低不等于模型推理差，而是 **GT 步骤覆盖判定** 对 7B Judge 过严。

6. 论文对 Accuracy 的定义（非 exact match）

论文 Methods 与代码 `acc_diagnose.txt`（Prompt 19）一致：

- 1. 同一疾病可有多种别名（如 Heart disease / Cardiac disease）
- 2. 不同表述可指同一病（如 heart attack / myocardial infarction）
- 3. 只评诊断是否正确，病因/症状/治疗建议不在范围内
- 4. 预测中包含 GT 诊断、额外提到并发症，**仍算正确**

实现方式：Judge 输出 `Correct|Wrong`，**不是**字符串相等比较。

7. Efficiency / Factuality / Completeness 指标定义

本节综合 [MedR-Bench 论文 Methods](#) 与仓库实现（`reasoning_eval.py + metrics/instructions/`），说明三个推理质量指标的含义、计算方式与 Judge 输入。

7.1 共同前提：推理链如何被切分

被评模型输出经 `split_reasoning()` 解析为步骤列表：

- 优先匹配 `<step n> ...` 格式（Gemini 等模型的标准输出）；
- 若无 step 标记，则按空行或换行切分；
- 默认最多取 10 步。

病例级分数 = 各步判定聚合后的一个 0–1 数值；**Completeness** 则在 GT 侧另走一条链路（见 7.4）。

7.2 Efficiency（效率）

论文定义

评估每个推理步骤是否对**最终答案**贡献**新的有效信息**，而非重复、引用病历或无关冗余。
Efficiency = **有效推理步数 / 全部预测步数**（类似“有效步占比”）。

实现流程（逐步分类）

对预测推理链中**每一步**，Judge（Prompt: `reasoning_efficiency.txt`）在以下输入下做四分类：

输入	内容
当前步	待分类的推理文本
之前各步	已出现的推理历史
病例摘要	<code>case_summary</code>
最终推理目标	<code>final_diagnosis</code> （GT 最终诊断说明， 非 模型预测答案）

四类标签：

标签	含义
Citation	仅复述/引用病历信息，无新推理
Repetition	重复已有推理，无推进
Reasoning	产生新信息或新结论，推动诊断（有效步）
Redundancy	有新内容但对达成最终答案无帮助

计算公式

Efficiency = (# 被判为 Reasoning 的步数) / (# 预测推理总步数)

- 分子：有效推理步；分母：全部预测步（含 Citation / Repetition / Redundancy）。
- 若总步数为 0，则 Efficiency = 0。

解读

- 高 Efficiency**：推理链紧凑，少废话、少重复引用。
- 低 Efficiency**：大量逐步复述检查所见或重复前文（Qwen-QwQ 在论文中因此偏低）。
- 注意**：Efficiency 的 Judge prompt **显式提供 GT 最终诊断**作为“推理目标”，这与“答案诱导偏差”研究直接相关（见第 10 节）。

7.3 Factuality（事实性 / 真实性）

论文定义

在**有效推理步**（Reasoning 类）中，评估其是否符合医学指南或客观事实。
Factuality = **事实正确的有效步数 / 有效推理步总数**（类似 precision）。

实现流程（仅对 Reasoning 步）

对每一步若分类为 Reasoning，Judge（Prompt: reasoning_factuality.txt）判断该步医学陈述是否正确：

输入	内容
病例摘要	case_summary
待判文本	该推理步
外部知识	论文：Bing 搜索结果；本次：关闭搜索，仅用病例 + Judge 内部知识

Judge 输出 JSON：{"judgment": "Correct|Wrong|Search", "keywords_to_search": ...}

- 若判 Search 且允许搜索 → 检索后再判；
- 本次 --no-web-search 时，强制 Judge 仅依据病例摘要做最终 Correct/Wrong 判定。

计算公式

Factuality = (# Reasoning 步中 factulity=true 的步数) / (# Reasoning 步数)

- 非 Reasoning 步（Citation 等）**不参与** Factuality 分母。
- 若无 Reasoning 步，Factuality = 0。

解读

- **高 Factuality**：有效推理步中的医学事实、逻辑依据可靠。
- 论文 oracle 设定下 Gemini-2.0-FT 约 **98%**，说明在信息充分时幻觉较少。
- 本次 Qwen-7B 无搜索仍得 **98.15%**，与论文接近，说明该维度对 Judge 型号相对不敏感。

7.4 Completeness（完整性）

论文定义

衡量模型生成的推理内容**覆盖**了病例报告/reference 中多少**关键推理步骤**。
Completeness = **被覆盖的 GT 步骤数 / GT 总步骤数**（类似 recall）。

GT 推理来源（代码）：

gt_reasoning = differential_diagnosis + "\n Final diagnosis:\n" + final_diagnosis

即：鉴别诊断过程 + 最终诊断说明，**不是**简短的 `diagnosis_results` 一句话。

实现流程（两阶段，均依赖 Judge）

阶段 A — 拆分 GT 推理（Prompt: `reasoning_split_gt_steps.txt`）

- 输入：上述 `gt_reasoning` 长文本；
- Judge 重组为 ≤10 条原子步骤（<Step k> ... 或换行分隔）；
- 输出写入结果 JSON 的 `gt_reasoning_eval[].step`。

阶段 B — 逐步覆盖检测（Prompt: `reasoning_check_hit.txt`）

对每条 GT 步骤，Judge 判断：

- 该 GT 步骤的核心含义/逻辑，是否出现在**模型预测推理链**（`combined_reasoning`）中？
- 输入：**GT 单步 + 模型完整推理文本**（不含 `### Answer` 最终诊断句，除非落在推理段内）；
 - 输出：**Yes|No**（代码用 `'yes' in output.lower()` 解析）。

计算公式

Completeness (recall) = (# hit=true 的 GT 步数) / (# GT 总步数 M)

解读

- **高 Completeness**：模型推理链覆盖了 reference 讨论中的大部分关键论证（排除项、影像依据、病理确认等）。
- **低 Completeness**：模型可能得出正确诊断，但未按 reference 方式展开全部推理环节。
- 论文指出 Completeness 是临床可靠性中最薄弱的环节之一（多数模型 70-80%+，仍常遗漏关键步骤）。

7.5 三指标关系一览

维度	评什么	分母	是否用 GT 最终诊断	是否用 GT 推理 reference
Efficiency	预测链是否啰嗦	预测总步数	是（作推理目标）	否
Factuality	有效步是否医学正确	Reasoning 步数	否（仅用 case）	否
Completeness	预测链是否覆盖 reference	GT 步数 M	否	是（拆分后逐步比对）
Accuracy	最终诊断是否正确	1（病例级）	是（pred vs GT）	否

8. Completeness 差距较大：原因深度分析

本次 Qwen-7B Completeness **31.47%** vs 论文 GPT-4o **83.28%**，差距 **-51.8 pp**，远大于 Efficiency（-2.3 pp）与 Factuality（-0.1 pp）。以下为分层原因分析。

8.1 原因一：Judge 能力差异（主因，已有实证）

同一推理文本、同一套代码，仅更换 Judge：

Judge	样本	Completeness	每例平均 hit 率
GPT-4o	35 例	74.79%	~75%
Qwen-7B	35 例	32.68%	~33%
Qwen-7B	957 例	31.47%	~31%

说明：**不是 957 例聚合错误**，而是 Qwen-7B 在 `check_step_hit` 任务上**系统性更常输出 No**。

典型案例 **PMC11625232**：模型与 GPT Judge 均达 recall=100%；Qwen Judge 仅 55.6%（5/9 hit）。
案例 **PMC11321471**：模型 6 步推理清晰指向 GIST，Efficiency/Factuality=1.0，但 **10/10 GT 步全判未覆盖** → recall=0%。

机制：Completeness 要求 Judge 做**跨文本**语义对齐（GT 步骤 ↔ 自由文本推理链），比 Efficiency 四分类、Factuality 单步真伪判断更难；7B 模型在此类“是否涵盖”任务上校准不足，倾向保守拒判。

8.2 原因二：GT 拆分本身也依赖 Judge（误差累积）

Completeness 流水线中有 **两次** Judge 调用链：

```
gt_reasoning 长文本
  → [Judge-1] split_ground_truth_reasoning → M 条 GT 步骤
  → [Judge-2] check_step_hit × M 次 → hit / no-hit
```

- **Judge-1** 决定分母 M 及每步粒度：拆得更细 → 更难全部 hit；措辞更偏 reference 原文 → 与模型表述差异更大。
- **Judge-2** 决定分子：语义等价但表述不同时，GPT-4o 更易判 Yes，Qwen-7B 更易判 No。
- 两次调用**均用同一 Judge** 时，误差**累积**；换 Judge 后，同一病例的 GT 步骤文本也会变（PMC11625232：Qwen 9 步 vs GPT 8 步，文本不完全相同）。

论文人工验证：Completeness 相关步骤人工一致率约 **90%**（低于 Effectiveness 98%、Factuality 99%），本身即最 noisy 的环节；换弱 Judge 会进一步放大噪声。

8.3 原因三：GT reference 与模型推理的“体裁 mismatch”

来源	文体	典型内容
GT differential_diagnosis	病例报告 discussion 提炼	排除项列表、病理/免疫组化确认、随访结局
模型 gemini2-ft 推理	按 prompt 生成的 step-by-step 链	从主诉→检查→综合→答案，未必逐步写“排除 cavernous sinus thrombosis”

Completeness 要求的是 **reference 步骤是否在预测链中出现**，不是“诊断是否正确”。因此：

- 模型**诊断对、推理合理**，仍可能 Completeness 很低；
- 模型逐步**引用**病历（Citation 多）时 Efficiency 下降，但 Completeness 取决于是否触及 GT 讨论的每个要点。

这对 **731 例 recall<50%**（73.5%）的分布具有解释力：多数不是“模型没推理”，而是 **reference 粒度与模型表述不对齐 + Judge 对齐能力差**。

8.4 原因四：解析与实现细节（次要，但可改进）

问题	影响
check_step_hit 用 'yes' in output.lower()	Judge 若输出 “Yes, partially” 或长句含 “not yes” 可能误判

问题	影响
<code>split_reasoning</code> 与 GT split 格式不一致	模型用 <code><step n></code> , GT 用 <code><Step n></code> 或纯文本, 对齐更难
GT 最多 10 步 cap	长 discussion 被截断, 分母与 reference 不完全等价
无网页搜索	对 Completeness 影响较小 (hit-check 不用搜索) ; Factuality 已验证影响小

8.5 原因五：与 Accuracy / Factuality 表现“背离”的解释

现象	解释
Accuracy 81% vs 论文 87%, 差距 moderate	最终诊断匹配 ; Judge 语义等价判定略严
Factuality 98% $\approx$ 论文	逐步医学事实判断, 7B 与 4o 在 oracle 完整信息下表现接近
Completeness 31% $\ll$ 论文 83%	跨段语义覆盖 最难 ; 7B 不适用 ; reference 体裁 mismatch 放大

结论：Completeness 差距**不能**解读为“模型推理质量比论文差 50 个百分点”，而应解读为：**在当前 Judge + 实现下，Completeness 指标对 Judge 选择与对齐任务设计高度敏感，可比性最弱。**

9. 代码与评估入口

9.1 评估命令

```
# Accuracy
python oracle_diagnose_accuracy.py \
  --model gemini2-ft --sequential \
  --patient-cases
../data/MedRBench/diagnosis_957_cases_with_rare_disease_491.json \
  --model-outputs ../oracle_diagnosis.json \
  --output-dir ./acc_results_qwen_judge_paper_957

# Reasoning ( 无网页搜索 )
python oracle_diagnose_reasoning.py \
  --model gemini2-ft --sequential --no-web-search \
  --patient-cases
../data/MedRBench/diagnosis_957_cases_with_rare_disease_491.json \
  --model-outputs ../oracle_diagnosis.json \
  --output-dir ./reasoning_results_qwen_judge_paper_957
```

9.2 指标计算公式（代码层速查）

见第 7 节完整定义；核心公式：

- **Efficiency** = Reasoning 步数 / 预测总步数
- **Factuality** = 正确的 Reasoning 步数 / Reasoning 步数
- **Completeness** = GT hit 步数 / GT 总步数

9.3 已知代码细节

项	说明
factulity 拼写	历史 typo, 与论文 factuality 对应
check_step_hit	用 'yes' in output.lower(), 对非标准 Judge 输出较 fragile
Efficiency prompt 中的 {result}	传入 final_diagnosis (GT) , 非模型预测答案
无 --embedded-outputs	论文 oracle_diagnosis.json 为标准格式, 不需要该参数

10. 延伸研究：LLM Judge 的「答案诱导偏差」

10.1 研究问题（课题摘要）

在医学长链诊断推理中，LLM 评审是否真正评价**推理过程**，还是会被**最终诊断答案**牵引，产生系统性评分偏差？

核心假设：若 Judge 在评估推理链时已知晓正确（或错误）诊断，则 Efficiency、Factuality、Completeness 等维度可能**随答案条件变化**，而非仅反映推理本身质量——即 **answer-induced bias（答案诱导偏差）**。

10.2 MedR-Bench 框架中的“答案泄漏”触点

基于本仓库实现，以下环节与“是否向 Judge 暴露最终诊断”相关：

评估环节	当前是否暴露 GT/ 答案	暴露内容	偏差风险
Efficiency 逐步分类	是	Prompt 中 [Final Reasoning Goal] = final_diagnosis	高：Judge 已知正确结论，可能把“朝该结论推进”的步都标为 Reasoning
Factuality 逐步判断	间接	仅 case_summary + 推理步；但 case 常含检查结果	中：无显式答案，但病例摘要信息量大
Completeness hit-check	否（pred 链）	比对 GT 步骤 vs 模型推理文本	中：GT 步骤来自 differential + final_diagnosis, reference 本身含答案信息
Accuracy	是	pred 答案 vs diagnosis_results	预期设计：评结果，非评过程

对本课题的启示：MedR-Bench 原框架**并非**“纯过程评估”；Efficiency 尤其与 GT 诊断强绑定。你的课题若比较“加/不加/加错诊断”条件下各维度变化，**Efficiency 是最可能出现系统性偏移的维度**；Completeness 则可能因“Judge 已知 reference 含答案”而产生二次效应。

10.3 建议实验条件设计

在 MedR-Bench Oracle 诊断子集（957 或 491 罕见病）上，固定**同一条模型推理链**，仅改变 Judge 输入：

条件 ID	Judge 输入	目的
A — Process-only	病例摘要 + 推理链	基线：最少答案信息
B — Process + Correct DX	A + 正确 <code>diagnosis_results</code>	模拟当前 Efficiency 部分设定
C — Process + Wrong DX	A + 语义相关但错误的诊断	检验“错误锚点”是否仍抬高/压低过程分
D — Process + GT full	A + <code>final_diagnosis</code> 全文	对齐当前代码 <code>gt_answer</code> 用于 Efficiency
E — Counterfactual chain	固定诊断，替换推理链为“错但对”/“对但劣”	分离答案与过程质量

因变量（MedR-Bench 已有 + 可扩展）：

- Efficiency / Factuality / Completeness（复用现有 pipeline）
- 新增建议**：Evidence grounding（推理步是否有病例证据支撑）、Safety（是否出现危险建议）

统计：同一病例、不同条件下的 Δ score；配对检验；按 Accuracy 正确/错误子层分析。

10.4 基于本次 957 例结果的先行观察

观察	对答案诱导研究的含义
Factuality 98% 且与论文几乎一致	在 oracle 信息充分时，Judge 逐步真伪判断 相对稳定 ，可能较少受“最终答案”单独牵引（但仍需条件实验验证）
Completeness 31%（Qwen）vs 75%（GPT）	Judge 型号 >> 答案条件（尚未做消融）；换 Judge 优先于换答案作为混淆因素控制
PMC11321471：诊断对、Eff/Fact=1.0、Completeness=0%	说明 过程分与结果分可严重背离 ，支持“不能由 Accuracy 推断 Completeness”及答案诱导研究的必要性
Efficiency prompt 已含 GT 诊断	可直接做 B vs D vs A 消融，无需改数据，仅改 <code>reasoning_efficiency.txt</code> 中 <code>{result}</code> 字段

11. 后续可探索方向

结合 MedR-Bench 基础设施与本报告发现，建议按优先级展开：

11.1 短期（可立即在现有代码上改）

1. 答案条件消融实验
- 修改 `evaluate_efficiency()` 的 `{result}`：空 / 正确诊断 / 错误诊断 / 模型自报诊断；
 - 固定 Judge（建议至少 GPT-4o + Qwen-7B 各一套），跑 35 或 957 子集，量化 Δ Efficiency、 Δ Factuality、 Δ Completeness。

2. Completeness 实现鲁棒性

- 改进 `check_step_hit` : 严格解析 `Yes|No` ; 或改用 JSON 结构化输出 ;
- 对比 `'yes' in output` vs 结构化解析下 GPT/Qwen 差距是否缩小。

3. Judge 校准曲线

- 抽样 50–100 例, 人工标注 GT 步骤是否被覆盖 ;
- 计算 Qwen-7B / GPT-4o 的 precision-recall, 作为 Completeness 可信区间。

11.2 中期 (论文级实验)

4. 答案诱导 × 诊断正误分层

- 将 957 例按 `accuracy=true/false` 分组 ;
- 检验 : 错误诊断病例中, 提供“正确诊断”是否**虚高** Efficiency/Factuality (后见之明 bias) 。

5. 错诊断对照 (C 条件)

- 为每例构造 plausibly wrong diagnosis (同专科、相近症状) ;
- 检验 Judge 是否因“推理链与给定诊断一致”而给更高过程分——即结论**一致性偏差**。

6. 过程-结果解耦评分

- 引入**不看 Answer 段**的 Completeness (仅 `<step>` 段 vs GT) ;
- 与含 Answer 的条件对比, 测量答案段对 Completeness 的边际贡献。

7. 跨 Judge 一致性

- 同一条件、GPT-4o vs Qwen-32B vs Qwen-7B ;
- 报告 ICC / Kendall's W, 明确哪些维度可跨 Judge 比较。

11.3 长期 (课题延伸)

8. 扩展维度 : Evidence & Safety

- Evidence : 每步是否可回溯到 case_summary 中具体证据 ;
- Safety : 是否出现不当检查/治疗建议 ;
- 同样做 A/B/C 答案条件消融, 检验诱导偏差是否存在于新维度。

9. 人机对比基线

- 论文已邀请 6 名医师做 oracle 诊断 ; 可扩展为“医师评推理链”小样本基线, 与 LLM Judge 对比偏差方向。

10. 去偏方法

- Prompt 约束 : “不得依据最终诊断评判过程” ;
- 两阶段 Judge : 先盲评过程, 后评结果 ;
- 训练小型 process-only 评审模型, report bias reduction。

11.4 推荐的首发实验路径

Step 1

35 例 pilot → A/B/C/D 四条件 × 1 个 Judge → 看 Efficiency 是否显著漂移

Step 2

若漂移显著 → 扩至 491 罕见病 / 957 全量

Step 3

并行换 GPT-4o 与 Qwen-7B → 分离“答案诱导”与“Judge 能力”

Step 4

人工金标准 100 例 → 校准 Completeness 与 Factuality

Step 5

撰写：MedR-Bench 上 LLM-as-judge 的过程效率与答案诱导偏差

本报告 957 例数据可直接复用为：

- 条件 B/D 的现成近似（当前 Efficiency 实现）；
- 对照基线数值（Table 3.1）；
- **Completeness 低分的案例库**（如 PMC11321471）用于定性分析。

12. 建议使用方式

用途	建议
与论文 Table 3 Accuracy 对比	可参考，注明 Judge 为 Qwen-7B（约 -5.7 pp）
与论文 Table 4 Efficiency / Factuality 对比	可参考 ，结果接近
与论文 Table 4 Completeness 对比	不宜直接对比 ；需 GPT-4o 或更强 Judge
模型间相对排序（同 Judge）	有效
病例级错误分析	使用各 JSON 中的 accuracy 、 gt_reasoning_eval

若需对齐论文 Completeness（~83%），建议：

- 使用 **GPT-4o** 作 Judge（至少 completeness 的 split + hit-check），或
- 升级本地 Judge 至 **Qwen2.5-32B** 及以上再复跑 reasoning 评估

13. 汇总表（一页速查）

指标	论文	Qwen-7B 957	差距
Accuracy	86.83%	81.09%	-5.74pp
Efficiency	95.89%	93.61%	-2.28pp
Factuality	98.23%	98.15%	-0.08pp
Completeness	83.28%	31.47%	-51.8pp

运行状态：957/957 完整 ✓

推理数据：与论文 oracle_diagnosis.json 一致 ✓

主要差异：Judge 模型（Qwen-7B vs GPT-4o），Completeness 受影响最大

指标定义：见第 7 节 | Completeness 差距分析：见第 8 节

答案诱导研究：见第 10-11 节

报告由本地脚本 *scripts/analyze_reasoning_paper_957.py* 与人工复核生成。
第 7-11 节更新：指标定义、Completeness 深度分析、答案诱导偏差研究方向（2026-05-28）。