

Stage 1 实验报告：Demo 数据集推理评估

环境：GPU-P100-2 (2× P100 16GB)

数据：demo_diagnosis_100.json / demo_treatment_100.json (各 100 例, seed=42)

更新：2026-06-11 (Gemma-9B-it reasoning_eval 在服务器 4bit 重跑中, 本地 JSON 可能滞后)

1. 实验目标（预设）

编号	内容
Stage 1	选 100 diagnosis + 100 treatment 作为 demo, 先跑通全流程再决定 Stage 2
2.1	推理能力分层： Strong = o3-mini、deepseek-r1（API）； Weak = qwen3-8b、qwen3-14b（本地）
2.2	Gemma 2B / 9B 推理评估（MedRBench 三指标）， 两组 ：① direct 仅推理过程；② inference_augmented 推理 + 模型最终推断
P.S.	回答与推理均有对有错；先完成实验、汇总统计，再定下一步

2. Demo 100 例如何选取

2.1 脚本与数据源

由 scripts/data/build_demo_subset.py 生成，配置记录在 data/MedRBench/demo_stage1_manifest.json。

任务	全量池	规模	Demo 输出
Diagnosis	diagnosis_957_cases_with_rare_disease_491.json	957 例 (其中 491 例标记 rare)	demo_diagnosis_100.json
Treatment	treatment_496_cases_with_rare_disease_165.json	496 例 (其中 165 例标记 rare)	demo_treatment_100.json

随机种子：seed=42（可复现）。

2.2 抽样算法

Diagnosis（100 例） — 两阶段

1. 强制纳入：test_cases.json 中的 35 例全部入选（与 MedRBench 官方 35 例子集对齐，便于和已有评估对照）。
2. 再抽 65 例：从剩余池中按 与全库相同的 rare 比例 分层随机抽样（checked_rare_disease 非空视为 rare 病例）。

Treatment（100 例）

- 从 496 例池中 纯随机 抽 100 例（同样按 rare 比例分层，无 test35 强制纳入）。

核心逻辑见 build_demo_subset.py 中 _sample_ids()。

2.3 分布情况（相对全量池）

Diagnosis demo（100 例）

维度	Demo 100	全库 957	说明
Rare 病例	65（65.0%）	491（51.3%）	略高于全库 rare 占比（因含 35 例 test 子集 + 分层补齐）
含 test35	35/35	—	100% 覆盖官方 35 例

body_category（可多标签，计数之和 > 100）

类别	例数
Brain and Nerves	24
Digestive System	14
Bones, Joints and Muscles	11
Blood, Heart and Circulation	10
Kidneys and Urinary System	10
Lungs and Breathing	8
Skin, Hair and Nails	6
其他 / 空	若干

disorder_category

类别	例数
Cancers	34
Infections	30
Genetics/Birth Defects	19
Injuries and Wounds	5

类别	例数
Pregnancy and Reproduction	5
其他	若干

Treatment demo（100 例）

维度	Demo 100	全库 496
Rare 病例	51（51.0%）	165（33.3%）

Treatment 的 rare 占比 **明显高于** 全库（分层抽样保留 rare 所致），评估时需知 demo 偏 rare / 复杂病例。

body_category（top）：Bones/Joints/Muscles (30)、Blood/Heart (29)、Digestive (26)、Brain/Nerves (23) 等。

disorder_category（top）：Cancers (29)、Infections (16)、Injuries (16)、Genetics (15) 等。

2.4 复现命令

```
python scripts/data/build_demo_subset.py --seed 42
# 输出 demo_diagnosis_100.json, demo_treatment_100.json, demo_stage1_manifest.json
```

3. Stage 1 实验流程

```
flowchart TB
    subgraph data [数据]
        M[demo_stage1_manifest.json]
        D[demo_diagnosis_100.json]
    end

    subgraph s21 [2.1 Subject 推理]
        O[oracle_diagnosis.json → strong]
        Q[run_qwen_inference.py → weak]
        P[prepare_subject_outputs.py]
        S[oracle_diagnosis_subjects.json]
    end

    subgraph s22 [2.2 reasoning_eval]
        R[run_stage1_reasoning_eval.py]
        J[Gemma-2B-it / 9B-it Judge]
        OUT[data/Stage1/reasoning_eval/*.json]
    end

    M --> D
    O --> P
    Q --> P
    P --> S
    S --> R
    R --> OUT
```

```
R --> J
R --> OUT
```

3.1 命令速查 (diagnosis, 已完成部分)

```
# 1. 合并 subject 输出
python scripts/stage1/prepare_subject_outputs.py --task diagnosis

# 2. 弱模型推理 ( qwen3_infer 环境 )
python scripts/stage1/run_qwen_inference.py --task diagnosis --model qwen3-8b
python scripts/stage1/prepare_subject_outputs.py --task diagnosis

# 3. MedRBench 三指标 + 两组 ( direct / inference_augmented )
conda activate gemma_scope
export EVAL_DISABLE_WEB_SEARCH=1
python scripts/stage1/run_stage1_reasoning_eval.py \
    --task diagnosis --subject-model o3-mini \
    --judge gemma-local --gemma-size 2b

# 4. 9B-it Judge (P100:4bit 单卡 )
export CUDA_VISIBLE_DEVICES=0
export GEMMA_JUDGE_9B_MODE=4bit
python scripts/stage1/run_stage1_reasoning_eval.py \
    --task diagnosis --subject-model qwen3-8b \
    --judge gemma-local --gemma-size 9b

# 汇总
python scripts/stage1/summarize_reasoning_eval.py
```

进度查看 (每例写盘, 可断点续跑) :

```
python -c "
import json; from pathlib import Path
for p in sorted(Path('data/Stage1/reasoning_eval').glob('*.json')):
    d=json.load(open(p, encoding='utf-8'))
    ok=sum(1 for c in d['cases'].values() if c.get('status')== 'ok')
    print(p.name, f'ok={ok}/', d['meta'].get('total_cases',100))
"
```

4. 完成度

4.1 Subject 推理 (diagnosis)

模型	分层	覆盖
o3-mini	Strong	100/100
deepseek-r1	Strong	100/100

模型	分层	覆盖
qwen3-8b	Weak	100/100
qwen3-14b	Weak	0/100
treatment 100 例	—	未开始

4.2 reasoning_eval (Gemma-it Judge)

Judge	Subject	direct	inference_augmented
Gemma-2B-it	o3-mini	☑ 100/100	☑ 100/100
	deepseek-r1	☑ 100/100	☑ 100/100
	qwen3-8b	☑ 100/100	☑ 100/100
Gemma-9B-it	qwen3-8b	🔄 4bit 重跑中	🔄 同上
	o3 / deepseek	✗ 未跑	✗

5. 结果汇总 (Gemma-2B-it, diagnosis 100 例)

指标 (MedRBench reasoning_eval.py, 无 web search) :

- **Efficiency** : 有效推理步占比
- **Factuality** : Reasoning 步中事实正确比例
- **Completeness (recall)** : GT 推理步骤被覆盖的比例

Subject	组别	Efficiency	Factuality	Completeness
o3-mini	direct	99.3%	93.4%	78.5%
	inference_augmented	98.9%	92.9%	79.7%
deepseek-r1	direct	99.7%	92.4%	78.2%
	inference_augmented	99.6%	92.1%	80.7%
qwen3-8b	direct	99.6%	92.2%	78.8%
	inference_augmented	99.1%	92.2%	80.7%

组间 : inference_augmented 使 Completeness +1.2 ~ +2.5 pp ; Efficiency / Factuality 几乎不变。

模型间 : Strong 与 Weak 无法区分 (Efficiency ~99% 饱和 ; Factuality ~92-93% ; Completeness ~78-80%) 。

补充 : o3-mini 平均推理步数约 5.7 步/例 (direct, 范围 2-8) 。

6. 分析与结论

目标	结论
Demo 流程跑通	☑

目标	结论
2.2 两组设计有效	☒ inference_augmented 稳定提高 Completeness
2.1 Strong/Weak 分层	☒ Gemma-2B-it 三指标 不能 分层

P.S. 核心认识：Judge 评的是推理链是否「像样」、是否覆盖 GT 步骤，**不等于**最终诊断是否正确。下一步应补 **Accuracy**，并按推断对错分层再看 reasoning。

Stage 2 建议： P0 Accuracy ; P1 qwen3-14b + treatment ; P2 9B-it 结果对比（若仍无分层则换更强 Judge）。

7. 输入 / 输出示例

7.1 输入：病例摘要（PMC11625232）

Subject 模型收到的 `case_summary`（来自 `demo_diagnosis_100.json` → `generate_case`）：

```
- **Patient Information:** 13-year-old male
- **Chief Complaint:** Severe left eye pain
- **History of Present Illness:** Eyelid edema, erythema, localized warmth of the
  left eye; recent severe nasal congestion and headaches.
- **Physical Examination:** Febrile (39.5°C), with signs of orbital inflammation.
- **Ancillary Tests:**
  - Elevated CRP (306.9 mg/L), leukocytosis, neutrophilia.
  - NCCT: thickened orbital tissue; maxillary sinus obliteration; small frontal
    epidural empyema.
  - NCMRI: confirms sinusitis, periorbital cellulitis, epidural empyema.
```

GT 诊断 (`diagnosis_results`) : `Orbital cellulitis secondary to acute sinusitis with frontal epidural empyema.`

7.2 输入：Subject 模型输出（o3-mini，节选）

`data/Stage1/oracle_diagnosis_subjects.json`：

```
### Reasoning:
<step 1> The patient is a 13-year-old male presenting with severe left eye pain,
eyelid edema, erythema, and localized warmth, indicative of orbital inflammation.

<step 2> Recent nasal congestion and headaches suggest a sinus-related source...

<step 6> The combination of orbital cellulitis, maxillary sinusitis, and frontal
epidural empyema suggests infection spreading beyond sinuses and orbit.

### Answer:
Orbital cellulitis with associated maxillary sinusitis and frontal epidural empyema.
```

Qwen3-8B 格式类似，常带 `` 围栏和 `### Resoning` 拼写。

7.3 inference_augmented 组构造

在 direct 的 `<step N>` 列表末尾追加：

```
Final model inference: Orbital cellulitis with associated maxillary sinusitis and frontal epidural empyema.
```

7.4 输出：reasoning_eval (Gemma-2B-it, direct)

文件：`data/Stage1/reasoning_eval/diagnosis_gemma-2b-it_o3-mini_direct.json`

Case 级

```
{
  "status": "ok",
  "group": "direct",
  "step_count": 6,
  "efficiency": 1.0,
  "factuality": 1.0,
  "recall": 0.9
}
```

逐步 Efficiency / Factuality

```
{
  "step": "Physical examination reveals fever (39.5°C)...",
  "efficiency": "Reasoning",
  "factuality": true,
  "judgment_path": [{ "judgment": "Correct", "keywords_to_search": "None" }]
}
```

Completeness (GT 步骤 hit-check)

```
{
  "step": "<Step 3> Small empyema was identified by NCCT and confirmed by NCMRI...",
  "hit": true
}
```

8. 产出文件索引

路径	说明
<code>data/MedRBench/demo_stage1_manifest.json</code>	100 例 ID、seed、数据源

路径	说明
data/MedRBench/demo_diagnosis_100.json	Diagnosis demo 全字段
data/Stage1/oracle_diagnosis_subjects.json	合并 subject 输出
data/Stage1/reasoning_eval/diagnosis_gemma-{2b,9b}-it_{subject}_{group}.json	评估结果
scripts/data/build_demo_subset.py	构建 demo 子集
scripts/stage1/run_stage1_reasoning_eval.py	2.2 主评估
scripts/stage1/gemma_judge_backend.py	Gemma-it 本地 Judge

9. 环境与待办

环境 / 问题	说明
<code>gemma_scope</code>	torch 2.1.2, transformers 4.44.x
<code>qwen3_infer</code>	Qwen3 本地推理
9B-it Judge	P100 推荐 <code>GEMMA_JUDGE_9B_MODE=4bit</code> + 单卡
断点续跑	<code>status==ok</code> 跳过, <code>error</code> 重试

待办：9B-it qwen 跑完并同步；qwen3-14b；treatment 100 例；diagnosis Accuracy。